# Tech Challenge – Fase 2

Classificação da Qualidade de Vinhos com Machine Learning

*Relatório de Resultados*

Pós-graduação em Data Analytics — FIAP

# 1. Contexto e Objetivo

A avaliação da qualidade de um vinho é tradicionalmente feita por especialistas, por meio de análises sensoriais que consideram aroma, sabor, acidez e equilíbrio. Esse processo é subjetivo, demorado e depende da experiência do avaliador.

O objetivo deste projeto é desenvolver um modelo de classificação capaz de prever a qualidade de um vinho a partir de suas características físico-químicas, apoiando enólogos e produtores na tomada de decisão e contribuindo para a padronização da qualidade.

Para simplificar o problema, a nota de qualidade (que varia de 3 a 8) foi transformada em uma variável binária:

- Alta qualidade: nota ≥ 7 → classe 1
- Baixa/Média qualidade: nota < 7 → classe 0

# 2. Base de Dados

Foi utilizada a base Wine Quality Dataset (Kaggle), com 1.143 amostras de vinho e 11 características físico-químicas: acidez fixa, acidez volátil, ácido cítrico, açúcar residual, cloretos, dióxido de enxofre livre e total, densidade, pH, sulfatos e teor alcoólico. A coluna "Id" foi removida por ser apenas um identificador, sem relação com a qualidade.

Verificação de qualidade dos dados: a base não possui valores faltantes. Foram identificados 125 registros duplicados, avaliados durante a análise.

# 3. Análise Exploratória dos Dados (EDA)

## 3.1 Distribuição da nota de qualidade

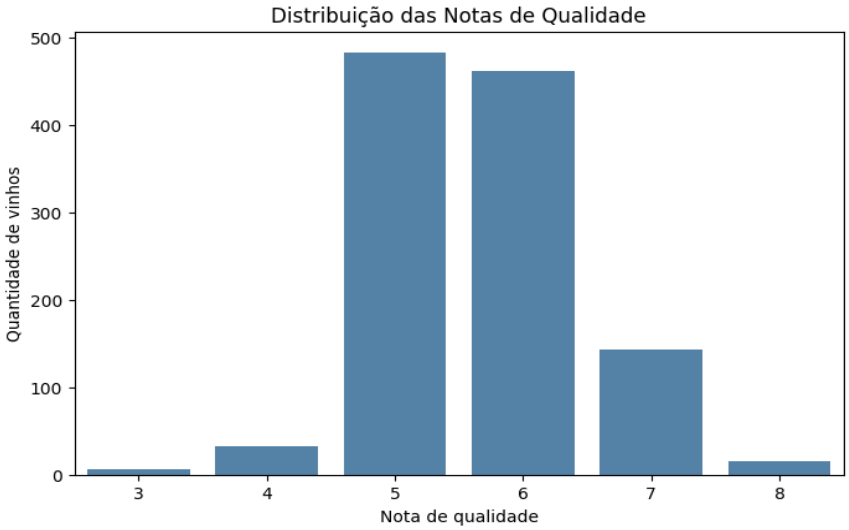



*Figura 1 — Distribuição das notas de qualidade (3 a 8).*

A grande maioria dos vinhos concentra-se nas notas 5 e 6. Notas altas (7 e 8) e muito baixas (3 e 4) são raras, o que já antecipa um desbalanceamento quando a variável é transformada em binária.

## 3.2 Balanceamento das classes

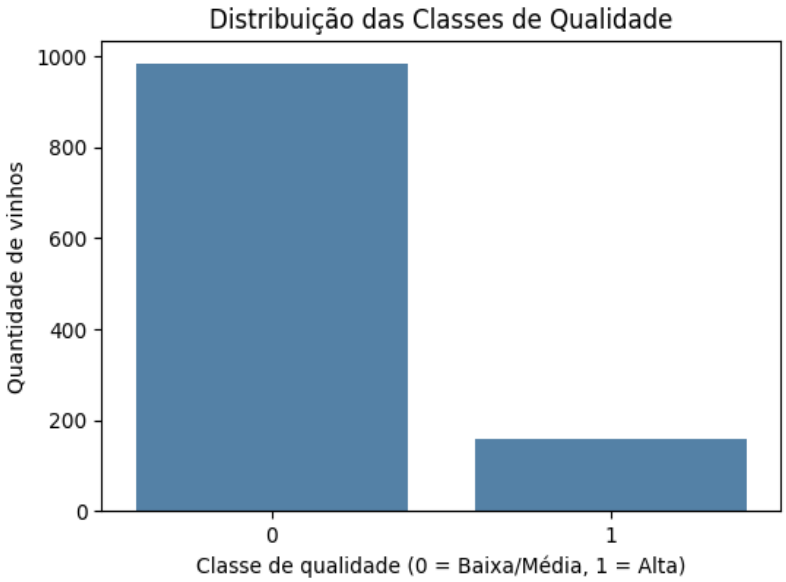



*Figura 2 — Distribuição das classes após a transformação binária.*

As classes são fortemente desbalanceadas: aproximadamente 86% dos vinhos são de baixa/média qualidade (classe 0) e apenas 14% são de alta qualidade (classe 1). Esse desbalanceamento é um ponto central do projeto, pois a acurácia isolada se torna uma métrica enganosa — um modelo que classificasse todos os vinhos como "baixa/média" já acertaria cerca de 86%. Por isso foram adotadas métricas adicionais (precisão, recall, F1 e ROC-AUC) e o parâmetro class_weight="balanced" nos modelos.

## 3.3 Distribuição das variáveis físico-químicas

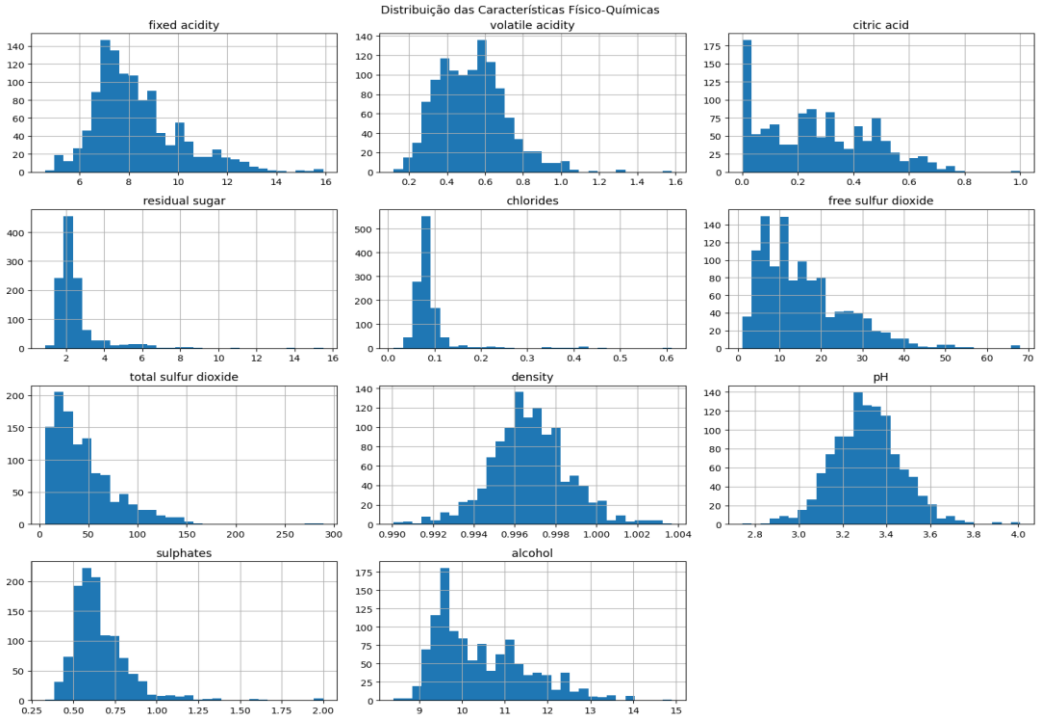



*Figura 3 — Histogramas das variáveis físico-químicas.*

Variáveis como açúcar residual, cloretos, sulfatos e dióxido de enxofre apresentam forte assimetria à direita (cauda longa), indicando a presença de valores extremos. Já densidade, pH e acidez volátil têm distribuição mais simétrica. Essa diferença de escala e formato justifica a padronização das variáveis antes da modelagem.

## 3.4 Detecção de outliers

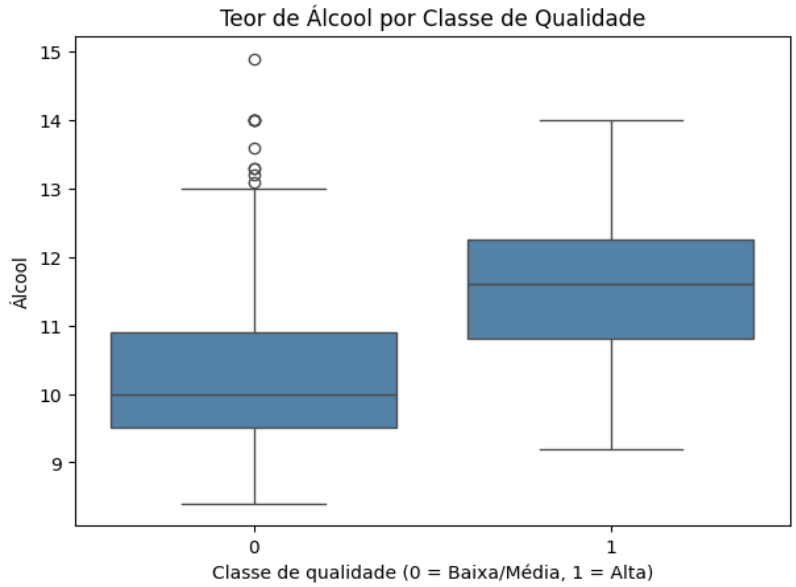



*Figura 4 — Teor de álcool por classe de qualidade.*

O boxplot do teor de álcool já evidencia uma separação clara entre as classes: vinhos de alta qualidade (classe 1) tendem a ter maior teor alcoólico. Essa é a primeira pista visual de que o álcool é uma variável relevante para a qualidade.

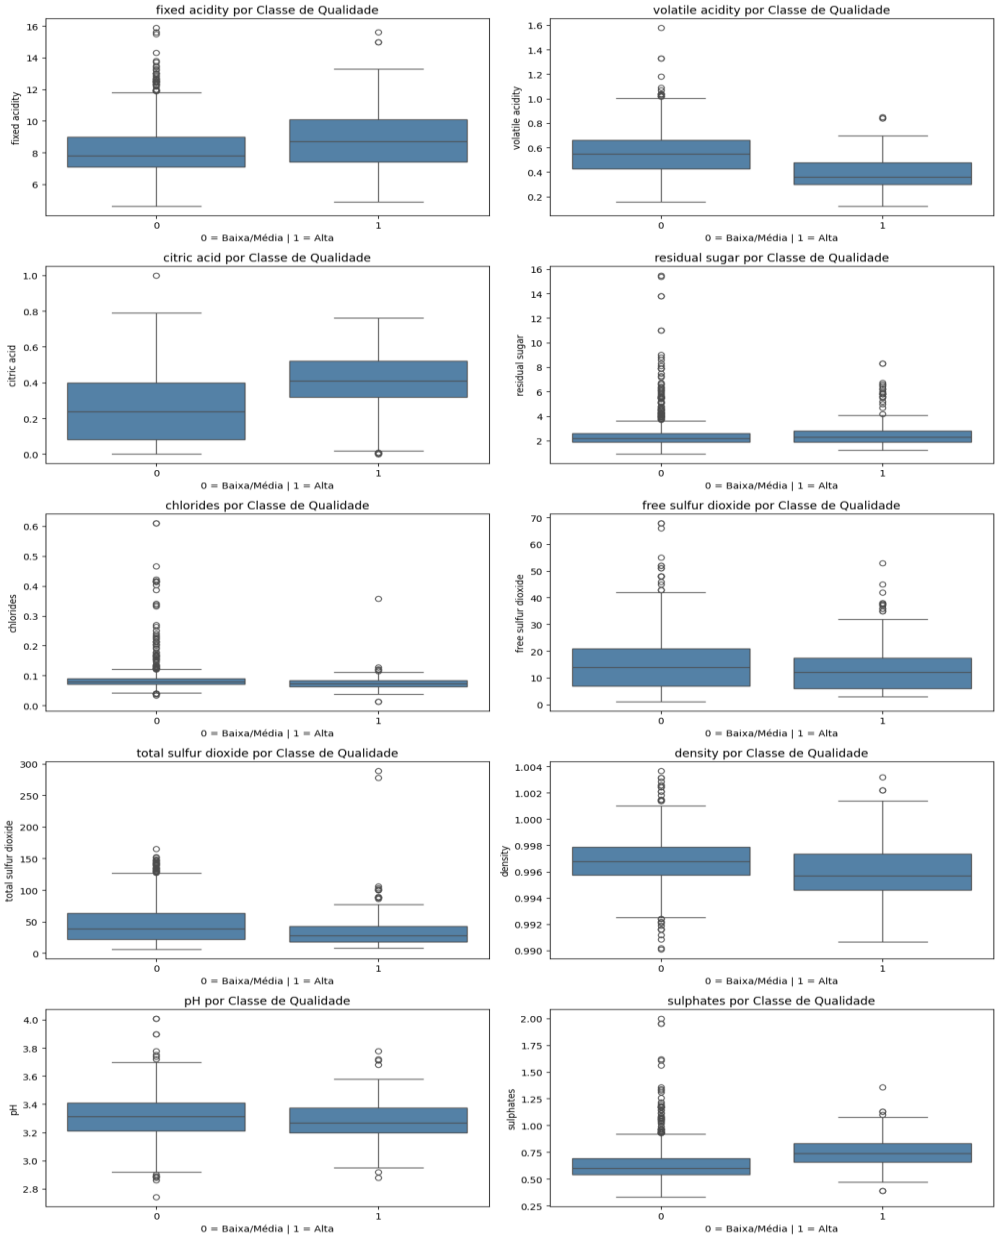



*Figura 5 — Boxplots de todas as variáveis por classe de qualidade.*

Praticamente todas as variáveis apresentam outliers. A decisão adotada foi não remover esses valores, pois podem representar vinhos reais e válidos; além disso, a classe de alta qualidade já é escassa e o dataset é relativamente pequeno, de modo que a remoção poderia descartar informação legítima. Optou-se por tratar a questão via padronização e pelo uso de modelos robustos a outliers (árvores).

## 3.5 Correlações

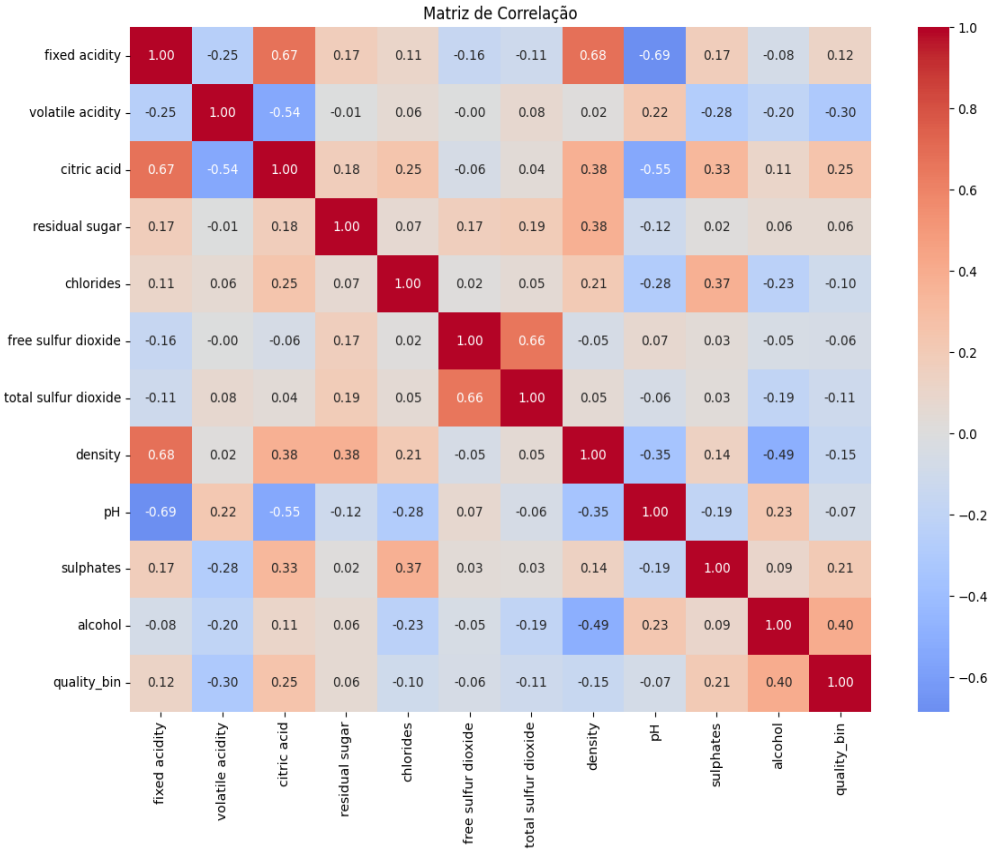



*Figura 6 — Matriz de correlação entre as variáveis.*

Analisando a relação de cada variável com a qualidade (quality_bin), destacam-se:

- alcohol (+0,40): maior correlação positiva — mais álcool tende a indicar maior qualidade.
- volatile acidity (−0,30): maior correlação negativa — excesso de acidez volátil reduz a qualidade (associado a sabor avinagrado).
- sulphates (+0,21) e citric acid (+0,25): contribuições positivas moderadas.

Observa-se ainda correlação alta entre algumas variáveis preditoras (fixed acidity × pH = −0,69; fixed acidity × citric acid = +0,67; free × total sulfur dioxide = +0,66), indicando certa multicolinearidade. Vale lembrar que a correlação de Pearson capta apenas relações lineares; a importância das variáveis segundo o modelo (Seção 5) oferece uma visão complementar.

# 4. Pré-processamento

- Separação entre variáveis preditoras (X) e alvo (y = quality_bin). As colunas "Id" e "quality" foram removidas de X — esta última para evitar vazamento de dados, já que o alvo foi derivado dela.
- Divisão em treino (80%) e teste (20%) com estratificação, preservando a proporção das classes nos dois conjuntos.
- Padronização das variáveis com StandardScaler, ajustando (fit) apenas no conjunto de treino e aplicando (transform) em treino e teste, para evitar vazamento de informação do teste.

# 5. Modelagem e Avaliação

Foram treinados e comparados modelos de classificação. Para cada um, avaliou-se a matriz de confusão e as métricas de precisão, recall e F1, com atenção especial à classe 1 (alta qualidade), que é a mais difícil por ser minoritária.

## 5.1 Regressão Logística

Modelo linear, simples e interpretável, usado como referência (baseline). Com class_weight="balanced", obteve os seguintes resultados na classe 1:

| Métrica (classe 1) | Valor |
|---|---|
| **Precisão** | 0,38 |
| **Recall** | 0,69 |
| **F1-score** | 0,49 |
| **Acurácia geral** | 0,80 |
| **ROC-AUC** | 0,85 |

Perfil do modelo: alto recall e baixa precisão — encontra boa parte dos vinhos bons (69%), mas gera muitos alarmes falsos (classifica como "bom" vinhos que não são).

## 5.2 Random Forest

Conjunto de várias árvores de decisão, mais robusto e capaz de captar relações não-lineares. Resultados na classe 1 (versão balanceada):

| Métrica (classe 1) | Valor |
|---|---|
| **Precisão** | 0,80 |
| **Recall** | 0,50 |
| **F1-score** | 0,62 |
| **Acurácia geral** | 0,91 |
| **ROC-AUC** | 0,90 |

Perfil do modelo: alta precisão e recall moderado — quando afirma que um vinho é bom, acerta na maioria das vezes, mas deixa passar parte dos vinhos bons. Perfil oposto ao da Regressão Logística.

## 5.3 Gradient Boosting

Modelo de boosting, que constrói árvores sequencialmente corrigindo os erros anteriores. Resultados na classe 1:

| Métrica (classe 1) | Valor |
|---|---|
| **Precisão** | 0,67 |
| **Recall** | 0,56 |
| **F1-score** | 0,61 |
| **Acurácia geral** | 0,90 |
| **ROC-AUC** | 0,88 |

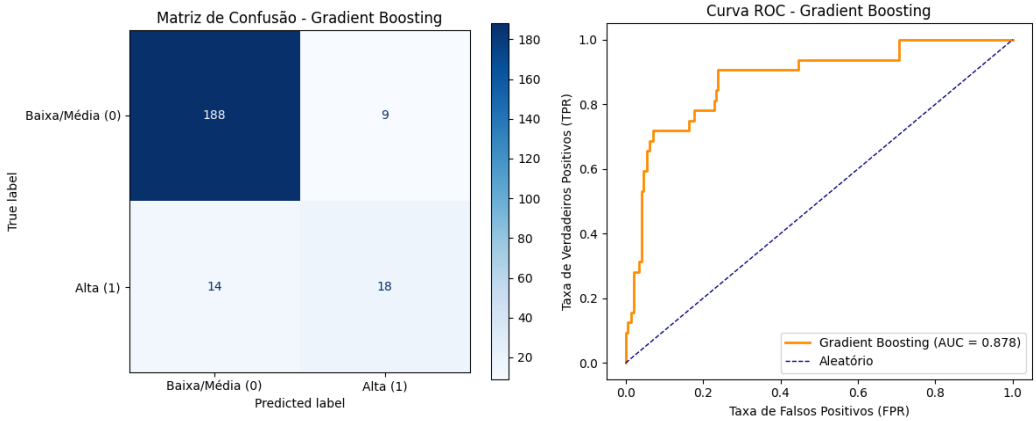



*Figura 7 — Matriz de confusão e curva ROC do modelo Gradient Boosting.*

## 5.4 Comparação entre os modelos

A curva ROC resume o desempenho dos modelos: quanto mais a curva se aproxima do canto superior esquerdo (e quanto maior a área sob a curva, AUC), melhor o modelo separa as classes.

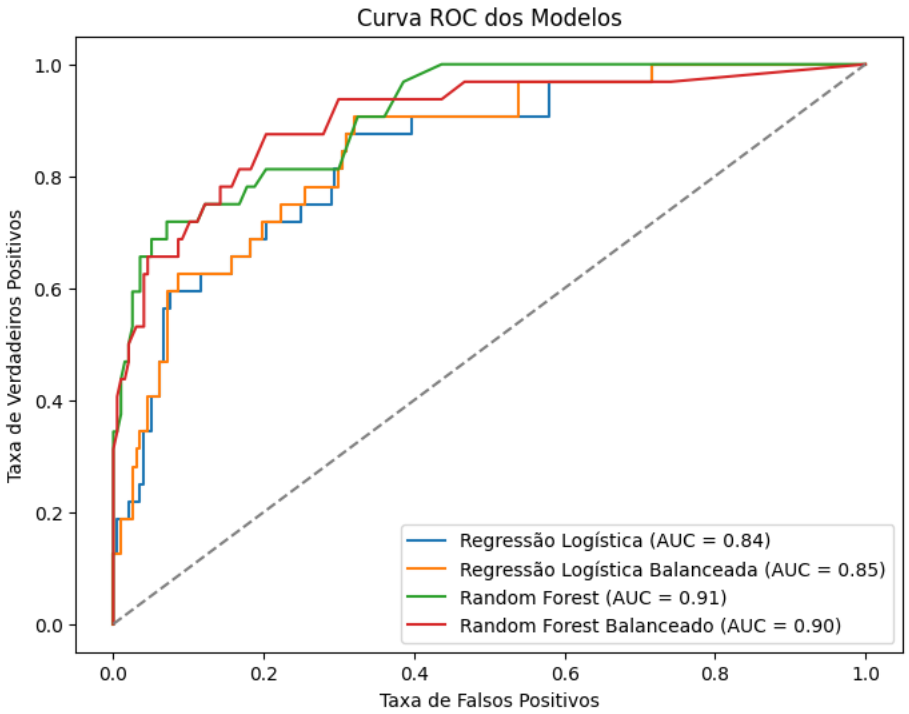



*Figura 8 — Curva ROC comparando os modelos avaliados.*

| Modelo | Precisão (1) | Recall (1) | F1 (1) | ROC-AUC |
|---|---|---|---|---|
| **Regressão Logística** | 0,38 | 0,69 | 0,49 | 0,85 |
| **Random Forest** | 0,80 | 0,50 | 0,62 | 0,90 |
| **Gradient Boosting** | 0,67 | 0,56 | 0,61 | 0,88 |

Conclusão da comparação: os modelos baseados em árvores (Random Forest e Gradient Boosting) apresentam o melhor equilíbrio geral, com ROC-AUC superior (0,90 e 0,88) ao da Regressão Logística (0,85). O Random Forest se destaca pela maior precisão e maior AUC, sendo o modelo recomendado. A escolha final, porém, depende do objetivo de negócio: se o mais importante for não perder vinhos bons, prioriza-se recall (Regressão Logística); se o mais importante for confiar na indicação de "alta qualidade", prioriza-se precisão (Random Forest).

## 6. Interpretação dos Resultados

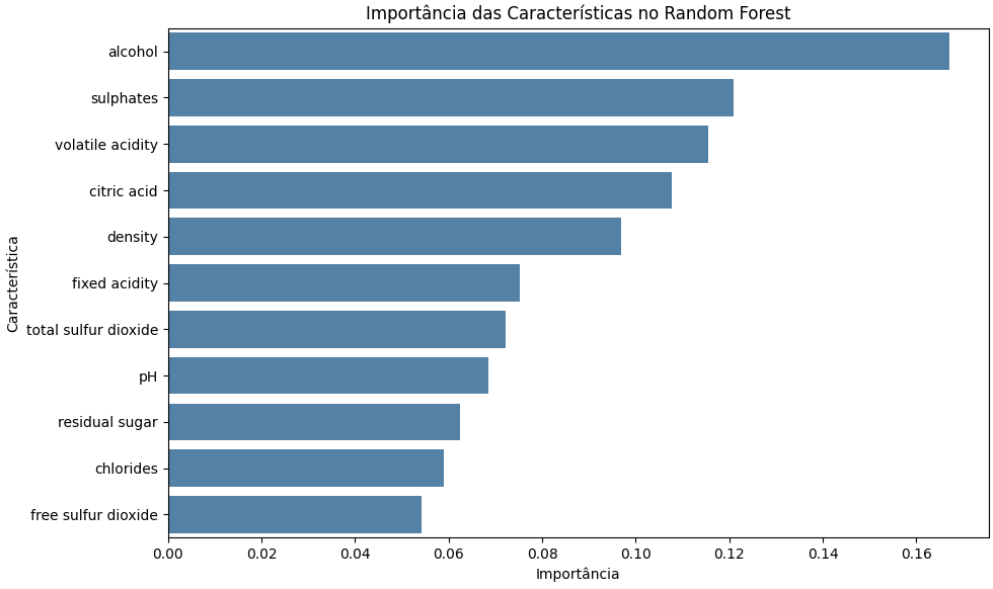



*Figura 9 — Importância das variáveis segundo o modelo Random Forest.*

As variáveis de maior influência na qualidade do vinho, de acordo com o modelo, são:

- alcohol (teor alcoólico) — a mais importante, confirmando o que a correlação e os boxplots já indicavam.
- sulphates (sulfatos) e volatile acidity (acidez volátil).
- citric acid (ácido cítrico) e density (densidade).

É interessante notar que a importância do modelo e a correlação linear nem sempre coincidem: sulfatos e ácido cítrico ganham destaque no Random Forest porque o modelo capta relações não-lineares e interações entre variáveis, algo que a correlação de Pearson não mede.

### Implicações para a produção

Como o teor alcoólico é o fator mais associado à qualidade, o processo de fermentação (que determina o álcool) surge como um ponto-chave de controle na produção. Sulfatos e acidez também aparecem como alavancas relevantes. Monitorar e ajustar essas variáveis pode contribuir para elevar e padronizar a qualidade dos vinhos produzidos.

## 7. Conclusão

O projeto percorreu todo o fluxo de um problema de classificação: compreensão do problema, análise exploratória, pré-processamento, modelagem, avaliação e interpretação. Os modelos baseados em árvores mostraram-se os mais adequados, com destaque para o Random Forest (ROC-AUC de 0,90). O teor alcoólico foi identificado como o principal determinante da qualidade, oferecendo uma recomendação prática e acionável para o processo produtivo. O principal desafio técnico foi o desbalanceamento das classes, tratado com estratificação, ponderação de classes e métricas apropriadas.